



南開大學
Nankai University

计算机学院
机器学习导论实验报告

作业二
三层 MLP 反向传播

姓名：赵健坤

学号：2010535

专业：计算机科学与技术

2022 年 11 月 11 日

目录

1 损失函数求导	2
2 反向传播：输出层	2
3 反向传播：隐藏层	3
4 反向传播：输入层	3
5 总结	4

1 损失函数求导

首先，将 $\text{tr}(S_w)$ 和 $\text{tr}(S_b)$ 表示为 $y_{i,j}^M$ 的函数：

$$\begin{aligned}\text{tr}(S_w) &= \sum_{c=1}^C \sum_{y_i^M \in c} \sum_j (y_{i,j}^M - m_{c,j}^M)^2 \\ &= \sum_{c=1}^C \sum_{y_i^M \in c} \sum_j \left(y_{i,j}^M - \frac{\sum_{y_k^M \in c} y_{k,j}^M}{n_c} \right)^2 \\ \text{tr}(S_b) &= \sum_{c=1}^C n_c \sum_j (m_{c,j}^M - m_j^M)^2 \\ &= \sum_{c=1}^C n_c \sum_j \left(\frac{\sum_{y_k^M \in c} y_{k,j}^M}{n_c} - \frac{\sum_{c=1}^C \sum_{y_k^M \in c} y_{k,j}^M}{\sum_{c=1}^C n_c} \right)^2\end{aligned}$$

然后求导，得：

$$\begin{aligned}\frac{\partial \text{tr}(S_w)}{\partial y_{i,j}^M} &= 2(y_{i,j}^M - m_{c,j}^M) + 2 \sum_{y_i^M \in c} (y_{i,j}^M - m_{c,j}^M) \cdot \left(-\frac{1}{n_c} \right) \\ &= 2(y_{i,j}^M - m_{c,j}^M) \\ \frac{\partial \text{tr}(S_b)}{\partial y_{i,j}^M} &= 2n_c(m_{c,j}^M - m_j^M) \cdot \frac{1}{n_c} + \sum_{c=1}^C n_c(m_{c,j}^M - m_j^M) \left(-\frac{1}{\sum_{c=1}^C n_c} \right) \\ &= 2(m_{c,j}^M - m_j^M)\end{aligned}$$

代入，求得损失函数对 $y_{i,j}^M$ 的导数：

$$\frac{\partial E}{\partial y_{i,j}^M} = (y_{i,j}^M - d_{i,j}) + \gamma(y_{i,j}^M + m_j^M - 2m_{c,j}^M)$$

改写为向量形式，其中每一个向量均表示第 i 个样本的对应值：

$$\frac{\partial E}{\partial \mathbf{y}^M} = (\mathbf{y}^M - \mathbf{d}) + \gamma(\mathbf{y}^M + \mathbf{m}^M - 2\mathbf{m}_c^M) \quad (1)$$

2 反向传播：输出层

输出层仅包含如下仿射变换，其中 \mathbf{y}^M 为输出的预测向量，维度为 M ； \mathbf{x}^N 为隐藏层输出向量，维度为 N ：

$$\mathbf{y}^M = W^{M \times N} \mathbf{x}^N + b^M$$

线性变换过程中权重及偏置项的梯度计算推导如下：

$$\begin{aligned}\frac{\partial y_i^M}{\partial w_{ij}} &= x_j \\ \frac{\partial E}{\partial W} &= \sum_{i=1}^N \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial W} = \frac{\partial E}{\partial \mathbf{y}^M} (\mathbf{x}^N)^\top\end{aligned} \quad (2)$$

$$\frac{\partial y_i^M}{\partial x_j^N} = w_{ij}$$

$$\frac{\partial E}{\partial X} = \sum_{i=1}^N \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial X} = W^\top \frac{\partial E}{\partial y^M} \quad (3)$$

$$\frac{\partial y_i^M}{\partial b_i^M} = 1$$

$$\frac{\partial E}{\partial b^M} = \frac{\partial E}{\partial y^M} \quad (4)$$

将(1)（反向传播输入）分别代入(2)、(4)，即可得到隐藏层权重和偏置项的梯度。(3)作为上一个隐藏层的反向传播输入继续向前传播。

3 反向传播：隐藏层

隐藏层可视作仿射变换与激活层的组合，若采用 sigmoid 函数，其前向传播可用以下方程描述，其中 \mathbf{z}^M 为隐藏层输出，维度为 M； \mathbf{x}^N 为隐藏层输入，维度为 N：

$$\mathbf{z}^M = \text{sigmoid}(\mathbf{y}^M)$$

$$\mathbf{y}^M = W^{M \times N} \mathbf{x}^N + b^M$$

激活层的求导结果如下：

$$\frac{\partial z_i^M}{\partial y_i^M} = z_i^M (1 - z_i^M)$$

即：

$$\frac{\partial \mathbf{z}^M}{\partial \mathbf{y}^M} = \mathbf{z}^M \odot (1 - \mathbf{z}^M) \quad (5)$$

其中 \odot 表示矢量对位相乘。根据(2)、(4)，隐藏层权重及偏置项梯度计算方法如下：

$$\frac{\partial E}{\partial W} = \sum_{i=1}^N \frac{\partial E}{\partial z_i} \frac{\partial z_i}{\partial y_i} \frac{\partial y_i}{\partial W} = \frac{\partial E}{\partial z^M} \odot \frac{\partial z^M}{\partial y^M} (\mathbf{x}^N)^\top \quad (6)$$

$$\frac{\partial E}{\partial X} = \sum_{i=1}^N \frac{\partial E}{\partial z_i} \frac{\partial z_i}{\partial y_i} \frac{\partial y_i}{\partial X} = W^\top \left(\frac{\partial E}{\partial z^M} \odot \frac{\partial z^M}{\partial y^M} \right) \quad (7)$$

$$\frac{\partial E}{\partial b^M} = \frac{\partial E}{\partial z^M} \odot \frac{\partial z^M}{\partial y^M} \quad (8)$$

$\frac{\partial E}{\partial z^M}$ 为从后续计算节点反向传播而来的梯度，由(3)（输出层）或(7)（上一隐藏层）反向传播而来。将(5)代入(6)和(8)即得隐藏层权重及偏置项梯度。

4 反向传播：输入层

输入层的权重及偏置项梯度计算公式与隐藏层完全相同，但不再需要对输入 \mathbf{x} 求导，直接使用(6)和(8)即可计算。

值得注意的是，一些教材认为输入 \mathbf{x} 直接构成输入层。按照这种定义，输入层没有参数，因此也

不需要反向传播。

5 总结

假定输入为 Q 维度向量 \mathbf{x} ，输入层、隐藏层、输出层维度分别为 P 、 N 、 M ，则输出层权重及偏置项梯度：

$$\begin{aligned}\frac{\partial E}{\partial W_3^{M \times N}} &= [(\mathbf{y}^M - \mathbf{d}) + \gamma (\mathbf{y}^M + \mathbf{m}^M - 2\mathbf{m}_c^M)] (\mathbf{z}_2^N)^\top \\ \frac{\partial E}{\partial b_3^M} &= [(\mathbf{y}^M - \mathbf{d}) + \gamma (\mathbf{y}^M + \mathbf{m}^M - 2\mathbf{m}_c^M)]\end{aligned}$$

隐藏层权重及偏置项梯度，其中 \odot 表示向量对位相乘。即 $A \odot B = \text{tr}(AB^T)$ ：

$$\begin{aligned}\frac{\partial E}{\partial W_2^{N \times P}} &= W_3^\top [(\mathbf{y}^M - \mathbf{d}) + \gamma (\mathbf{y}^M + \mathbf{m}^M - 2\mathbf{m}_c^M)] \odot \mathbf{z}_2^N \odot (1 - \mathbf{z}_2^N)(\mathbf{z}_1^P)^\top \\ \frac{\partial E}{\partial b_2^N} &= W_3^\top [(\mathbf{y}^M - \mathbf{d}) + \gamma (\mathbf{y}^M + \mathbf{m}^M - 2\mathbf{m}_c^M)] \odot \mathbf{z}_2^N \odot (1 - \mathbf{z}_2^N)\end{aligned}$$

输入层权重及偏置项梯度：

$$\begin{aligned}\frac{\partial E}{\partial W_1^{P \times Q}} &= W_2^T \{W_3^\top [(\mathbf{y}^M - \mathbf{d}) + \gamma (\mathbf{y}^M + \mathbf{m}^M - 2\mathbf{m}_c^M)] \odot \mathbf{z}_2^N \odot (1 - \mathbf{z}_1^N)\} \odot \mathbf{z}_1^P \odot (1 - \mathbf{z}_1^P)(\mathbf{x}^Q)^\top \\ \frac{\partial E}{\partial b_1^P} &= W_2^T \{W_3^\top [(\mathbf{y}^M - \mathbf{d}) + \gamma (\mathbf{y}^M + \mathbf{m}^M - 2\mathbf{m}_c^M)] \odot \mathbf{z}_2^N \odot (1 - \mathbf{z}_1^N)\} \odot \mathbf{z}_1^P \odot (1 - \mathbf{z}_1^P)\end{aligned}$$

如果认为输入 \mathbf{x} 直接构成输入层，则输入层没有权重和偏置项，用 \mathbf{x} 替换 \mathbf{z}_1 即可。